



四川大学

人工智能基础课程

期中作业

题名： 电影封面场景下的多模态情感识别

队长： 周彬 2024141450229

队员： 陈天胤 2024141450232

陈俞静 2024141450289

朱瀚超 2024141470214

冯宇菡 2024141450315

日期： 2026 年 6 月 5 日

摘要

本项目搭建面向电影海报与评论文本的双模态多模态情感识别系统，同步实现摄像头实时连续情感检测。视觉采用 ResNet18，文本使用 BERT，引入交叉注意力构建早 / 中 / 晚、注意力四类融合方案；通过加权交叉熵、离散情感先验、帧间自监督缓解数据失衡与预测抖动。实验表明交叉注意力融合最优，均衡准确率达 75%；单模态易混淆消极细粒度情绪，图文冲突时晚期融合存在视觉模态偏置。结合离散分类与 VAD 三维回归实现连续情感预测，搭配帧加权平滑完成实时人脸检测。项目验证多模态互补优势，同时存在自建数据集样本不平衡、模型结构改善、算力需求高等待优化问题。

引言

随着多媒体内容快速发展，电影宣传物料、用户影评构成图文混合情感载体，单一图像或文本模型难以完整捕捉影片整体情感倾向，传统离散表情识别也无法刻画情绪强弱动态变化，缺乏适配海报影评场景的端到端多模态情感分析方案，同时实时人脸连续情感检测存在识别抖动、样本不均衡等痛点。在此背景下，本项目开展图文双模态情感识别与实时连续情感检测研究，具备理论与应用双重价值。理论层面，对比四类模态融合架构优劣，结合注意力、自监督、离散先验优化情感模型，完善多模态情感计算融合策略；在应用层面，可用于影视内容情绪分级、观众观影偏好分析、实时人脸情绪捕捉等场景。项目以 RAF、FER 标准人脸数据集为基础，自建电影海报 - 影评图文数据集，分别完成单模态训练、多模态融合对比、摄像头实时连续情感识别全套实验，针对小样本类别失衡、图文语义冲突、实时预测跳变等行业常见问题提出轻量化改进方案，为影视多媒体情感分析与移动端实时情绪检测提供可行实践框架。

目录

1. 任务分析.....	
1.1 RAF, FER 基础数据集情感识别.....	
1.2 电影海报场景与评论的视觉与文字情感识别.....	
1.3 模态融合.....	
1.4 摄像头捕捉, 连续情感识别.....	
1.5 细分核心任务.....	
2. 训练模型与方法.....	
2.1 视觉情感网络.....	
2.2 文本情感网络.....	
2.3 注意力机制.....	
2.4 多模态融合模型.....	
2.5 训练策略.....	
2.6 摄像头人脸情感分析.....	
3. 结果分析.....	
3.1 RAF 和 FER 训练集.....	
3.2 电影封面.....	
3.3 电影评论.....	
3.4 多模态混合训练.....	
3.3 连续情感分析.....	
4. 创新点.....	
4.1 不平衡适应.....	
4.2 离散先验配合连续模型.....	
4.3 自监督网络.....	
5. 不足与提升优化空间.....	
5.1 学习策略与网络结构模型.....	
5.2 电影封面数据集.....	
5.3 自监督算力优化.....	
5.4 连续情感网络优化.....	
6. 参考文献.....	、
7. 成员分工.....	

5. 不足与提升优化空间.....	
5.1 学习策略与网络结构模型.....	
5.2 电影封面数据集.....	
5.3 自监督算力优化.....	
5.4 连续情感网络优化.....	

一、实验任务分析

1. 整体任务定位

本项目面向电影海报 + 评论文本的双模态场景，构建端到端多模态情感识别系统，属于多模态学习与情感计算的综合实践。根据任务核心与扩展要求，可将整体工作划分为基础视觉情感识别、电影海报与评论情感识别、多模态融合、摄像头实时检测与连续情感分析四个层次。

（一）RAF，FER 基础数据集视觉情感识别

- 1.数据集 RAF、FER。
- 2.使用网络 ResNet。
- 3.注意力引入：Transformer，Swin 滑动窗口注意力
- 4.训练策略：单独训练、联合训练

（二）电影海报场景与评论的视觉与文字情感识别

- 1.数据集爬取：线上爬取评论数据，总共 1000 张海报加上每部配 80 条评论。
- 2.数据清理：海报上，调用 opencv 与 mtcnn 进行人脸截取，抛弃无人脸海报
评论上，先使用 python 脚本进行数据清洗，再调用 Qwen2-1.5B-Instruct 模型进行筛选，获得专注人物的评论
- 3.模型训练：
 文本模型为 BERT，图像模型为 ResNet。

（三）模态融合

- 1.早期融合：相对并不适合文本与图像这种模态跨度较大的融合
- 2.中期融合：在特征层面融合，兼顾底层细节和高级特征
- 3.晚期融合：在晚期进行联合决策
- 4.注意力机制交叉融合：交叉关联，动态分配权重

（四）摄像头捕捉，连续情感识别（两个挑战任务）

找寻连续情感数据集训练连续情感模型，调取摄像头利用 OpenCV 与 MTCNN 截取人脸，并利用训练得到的连续情感模型进行情感预测。

（五）细分核心任务

a.数据集获取：

除了推荐的 RAF、FER 两个数据集外，还需要自行创建电影封面与评论数据库，以及对于连续情感等其他需求的数据库的寻找

b.视觉单模态任务：

基于 RAF、FER 和电影海报人脸的图像进行单模态情感识别，

c.文本单模态任务：

针对电影用户评论文本，完成三分类情感极性识别，类别为：积极情感（对应人脸的喜惊）、消极情感（对应人脸的怒哀厌惧）、中性情感（对应人脸平静）。

d.多模态融合任务：

实现两种主流融合范式：早期特征层融合、晚期决策层融合，构建双模态联合推理模型。

e.对比评测任务：

定量对比单模态模型、多模态融合模型的识别精度，分析不同模态的优劣与互补性。

f.特殊样本分析：

测试模型在海报情绪与评论情感极性相反的样本上的表现。

g.人脸截取与实时情感检测

调用摄像头，使用人脸识别模型截取人脸并使用训练好的模型进行实时检测

h.连续情感分析

希望利用具有连续情感标注的样本来实现连续情感强度模型建立，并进一步输出 VAD 等连续维度上的情感变化。

i.整体项目创新与优化

加入创新改善网络模型以及对于项目遇到其它问题的处理。

二、训练使用模型架构及方法

本项目模型结构主要由视觉分支、文本分支、注意力机制、模态融合模块三部分构成。

1. 视觉情感网络

模型：**ResNet18**

结构：基于残差连接的深度卷积网络，可有效提取图像的色彩、构图、人物、场景情绪特征

输入：自定义尺寸图像（代码中为 224）

输出：7 类情感预测结果

2. 文本情感网络

模型: **BERT**

结构: 基于 **Transformer** 的双向语言模型, 能精准理解文本情感倾向

输入: 文本内容

输出: 7 类情感极性预测结果

3. 注意力机制

Transformer: 双向 **Encoder**、单向 **Decoder** 两套模式覆盖理解+生成任务, 全局建模能力强, 适合长距离依赖直接捕捉

Swin 滑动窗口注意力: 视觉专用局部稀疏 **MSA**, 用窗口降低算力要求, 分层提取图像空间特征

4. 多模态融合模型:

A. 早期融合: 对于较大跨度模态, 早期融合效果欠佳, 未进行深究, 仅进行模型训练验证。

B. 晚期融合: 采用标准晚期融合, 两大模态分支完全独立推理, 仅在模型输出端融合预测结果。

C. 中期融合: 采用图像 + 文本双模态早期融合, 遵循先投影对齐、再特征拼接、最后统一分类的经典早期融合流程, 在特征层面最前端完成模态融合。

D. 注意力机制融合: 使用带交叉注意力的中期融合, 在双模态完成基础特征提取与维度对齐后, 引入多头交叉注意力实现图文深度交互。

5. 训练策略

A. 联合训练

B. 迁移训练

6. 摄像头人脸情感分析

A. 截取人脸工具: **opencv** (速度快), **mtcnn** (高性能)

B. 使用模型: 采用 **FER** 和 **RAF** 联合训练模型以及 **Emotic** 连续情感模型

三、实验结果及分析

与要求对应关系 (我们的序号-->题目序号) (**题目序号标红**)

(一) (二) -->1

(三) -->2

(四) -->3, 4, 5

（五）（六）-->挑战任务

本项目成功完成情感识别模型训练，共设置多轮迭代（Epoch），全程记录训练集、验证集损失（loss）、准确率（acc）和混淆矩阵，并完成最终测试集评估。以下分析在保留原有图片位置的基础上，结合每张图中的曲线走势、混淆矩阵分布和参考文字进行综合说明。

（一）RAF 和 FER 训练集（题目 1）




图 1 FER 训练损失与准确率曲线



图 2 FER 测试集混淆矩阵

图 1 展示了 FER 训练过程中的损失与准确率变化。可以看到训练损失随 Epoch 增加持续下降，训练准确率稳步提升，说明 ResNet 能够不断拟合训练集中表情纹理、五官变化和局部特征；但验证损失并没有同步下降，反而在前期短暂改善后逐步升高，验证准确率也长期处于波动上升状态。这说明模型在训练集上学习充分，但对验证集的迁移能力不足，已经出现较明显的过拟合趋势，且对于预测集的预测结果并不自信。

图 2 为 FER 测试集混淆矩阵。矩阵对角线颜色越深，代表该类别识别越准确；非对角线颜色越明显，代表类别间混淆越严重。从图中可以看出，七类情绪类别均能形成较清晰的对角线，说明模型对七类表情具备基本识别能力；但消极类情绪和中性情绪周围仍存在错分，说明悲伤、厌恶、恐惧、中性等边界相近类别容易互相干扰，而惊喜和开心的积极情绪分类效果较好。结合参考分析，模型更擅长区分积极与中性、消极两者间差异，但对消极和中性两极性内部的细粒度差异识别不足。







图3 RAF训练过程补充曲线与混淆矩阵

图3为RAF的训练曲线和混淆矩阵，存在与FER数据集相似的现象，不重复阐述

按道理面对过拟合应该先降低学习率，但这也意味着大量增加学习轮次和大量投入时间，故我们先尝试了注意力机制对其的改善效果






图 4.1 RAF (上) /FER (下) 注意力集加入训练曲线

图 4.1 为引入注意力机制（三个之间对比取较好者）后两数据集的训练曲线，过拟合问题虽然未被解决，但是准确率曲线上升期间的波动相对减小，说明引入注意力机制对于模型学习训练集特征有一定帮助





图 4.2 RAF (上) /FER (下) 注意力集加入训练曲线

如图 4.2 所示，在减小学习率后训练的波动减小，但准确的并没有得到有效的提高，在本次实验中，相对来讲增加注意力机制在减小波动的同时能够微小的提高准确率，而降低学习率可以减小波动，但对于准确率的提升没有贡献（其它一些注意力机制以及小学习率的曲线图以及混淆矩阵可以在 **results** 中查看，包括联合训练没有什么突出结果就不过多冗余分析，具体结果可以看 **results**）

FER 数据集上，前沿 SOTA 可以达到 74~77 的准确率，我们的最高准确率

为 70，RAF 数据集上，前沿 SOTA 能达到 90 的准确率，我们的最高准确率为 86，还有一定的优化空间

(二) 电影封面 (题目 1)



我们采集了老旧的和近几年新出的恐怖、搞笑的，阴沉的阳光的等多个时代多个类型的封面人脸图片

图 5 展示电影封面人脸训练曲线，图 6 展示电影封面人脸混淆矩阵。与标准 FER/RAF 表情数据相比，电影封面图像受光照、姿态、妆造、海报构图和艺术化处理影响更强，人脸表情也未必直接对应电影整体情绪，因此该任务比基础表情识别更复杂。




图 5 电影封面人脸训练曲线




图 6.1 电影封面人脸混淆矩阵 6.2 平衡后



图 6.3 电影封面人脸混淆矩阵 (迁移训练)

与 Emotic 数据集一样，两个样本都为小样本，故学习轮次较少，结合图 5 可以看出，电影封面模型在训练集上仍能持续收敛，说明裁剪后的人脸区域确实包含可学习的表情信息；但验证指标提升有限，说明封面场景中的噪声更强。

图 6.1 的混淆矩阵中，存在明显数据不平衡问题，预测结果聚集在大数据量的标签部分，模型被数据不平衡问题严重影响，我们通过一定平衡手段（创新中有细讲）降低了这一问题的影响，其结果图 6.2 显示，模型在厌恶和恐惧两个情感上的识别效果不好，其根本原因在于数据过少，模型学习到的特征有限,但开心和平淡情绪上效果较好，剩余情感预测也还算可以，在小样本的数据训练下已经达到了较为优秀的效果。后续通过迁移训练进一步提高预测效果，其结果如图 6.3 中所示

准确率表格（均衡准确率为七类单独准确率再相加除七）

训练策略	总准确率	均衡准确率
平衡前	55%	41%
平衡后	61%	49%
迁移训练	66%	55%

目前先进的方法在小样本数据集上的七类情感准确率普遍在 64~67 左右，我们在不用 RAF 和 FER 两个数据集的情况下（即不使用迁移训练），在 1000 样本的小数据集下达到了 61%的准确率，与先进方法仍存在一定距离

（三）电影评论（题目中是中好坏三类，其实只是把七类投射成三类）（题目 2）




图 7 电影粉包含人脸数;

图七为封面包含人脸数量（一定像素以上才使用），可以看出大部分为 1~3 个，为少数，故采用一对一来匹配人脸和评论，在预测上，对于一个封面有多个人脸上采用计算准确率汉明准确率，即一组内统计全部类别标签整体正确率。




图 8 电影评论训练曲线;




图 9.1 电影评论混淆矩阵




图 9.2 平衡后混淆矩阵

图 7 和图 8 说明，评论文本虽然能提供语义信息，但仍受评论内容弱相关性影响导致预测结果效果欠佳，平衡前基本不具备预测其它小数量感情的能力，经过平衡后模型有了一定的预测情感能力，但受本身相关性影响，效果仍然无法达到预期，但作为视觉的辅助模态依旧能提供一定帮助。

(四) 多模态混合训练。(题目 3)

A.早期（按理来说可能后面的中期融合也能算的上是一种早期）：图 10 对应早期融合结果。早期融合直接在特征层前端拼接图像与文本信息，优点是结构简单，但图像特征和文本特征语义跨度较大，若尚未充分对齐就直接融合，容易把两种模态中的噪声一起输入分类器。从图 9 曲线看，训练端仍能快速拟合，但验证端波动较明显；图 10 混淆矩阵中仍有较多非对角线区域，说明早期融合未能稳定解决类别混淆问题，虽然按照早期融合严格表标准，这样才算是早期融合，但这个显然不适用与模态跨度较大的文本与图像（故代码中就没有这部分了），可能后面所用的中期广义上也算是一种早期融合




图 10.1 早期融合训练曲线; 图 10.2 早期融合混淆矩阵

B.晚期：图 11 和图 12 对应晚期融合结果。晚期融合让图像分支和文本分支先独立完成预测，再在输出端进行联合决策，因此比早期融合更稳定，不容易因特征空间不一致导致训练崩坏。从图 11 可见，训练过程相对平滑，准确率提升较明显；图 12 中对角线整体更清晰，说明晚期融合能够利用两个单模态模型的互补信息。但它只在决策层合并结果，无法充分学习“某张海报表情与某段评论语义之间”的深层交互关系。




图 11 晚期融合训练曲线; 图 12 晚期融合混淆矩阵

C.中期：图 13 和图 14 对应中期融合结果。中期融合先将图像特征和文本特征投影到相近维度，再在特征层进行融合，因此比早期融合更有利于模态对齐。从图 13 看，训练损失下降较快，训练准确率提升明显；验证指标相比早期融合更稳定，但仍存在波动。图 14 混淆矩阵显示，对角线识别有所改善，但消极类和中性类仍有错分，说明中期融合能够增强互补性，却仍受数据噪声和情感边界模糊影响。




图 13 中期融合训练曲线; 图 14 中期融合混淆矩阵

D.注意力：图 15 和图 16 对应交叉注意力融合结果。该方法在基础图文特征

对齐后，引入多头交叉注意力，让文本特征关注图像中更相关的区域，也让视觉特征受到评论语义的引导。从图 15 看，训练准确率提升较充分，曲线收敛趋势较明显；图 16 混淆矩阵中对角线相对更完整，说明注意力融合对部分类别的识别有帮助。不过非对角线仍未完全消失，表明当海报表情与评论内容本身弱相关时，注意力机制也无法完全弥补数据逻辑上的不一致。




图 15 注意力融合训练曲线; 图 16 注意力融合混淆矩阵

准确率表格

融合策略	总体准确率	均衡准确率
------	-------	-------

早期	40%	28%
晚期	65%	58%
中期	75%	66%
注意力	81%	75%

准确率提升表格（题目 4）

融合策略	早期%	晚期%	中期%	注意力%
愤怒	-54	-9	3	3
厌恶	-27	6	6	40
恐惧	-30	3	3	37
开心	-33	-23	-18	-13
平淡	-24	6	4	13
伤心	-14	-1	13	27
惊喜	-20	24	45	47

在对于情感预测的提升上，这里以注意力机制融合为例，在不同情感上的预测提升上，原本效果最差的厌恶和恐惧得到了明显提升，惊喜的预测准确率得到了极大提升，高达 92%，其它各种情感处理上除原本就很高的高兴以及愤怒外也得到了不错的提升，并且在部分情绪的识别上是达到了一加一大于二的效果的，融合后的准确率高於二者预测之和。

在晚期融合的矛盾案例中（题目 5）

A.先从预测结果失败的来看



案例 0



案例 1



案例 2



案例 3

为分析晚期融合在图像与文本预测不一致时的决策特点，选取了多个融合预测错误的矛盾案例进行统计。这里举出部分具有代表性的例子

结果显示，前晚期融合模型存在明显的视觉模态主导现象：当两个分支发生冲突时，融合结果通常更倾向于采纳图像分支，即使文本分支已经给出正确判断，也未能有效纠正视觉误判。

具体来看，案例 0、1、2、3 中，文本分支分别正确识别了平淡、恐惧、悲伤、平淡，但融合结果仍跟随错误的图像预测。例如，案例 001 的真实标签为恐惧，文本分支预计依靠“去年夺命舰的成功和今年异形地球的扑街都证明，懂得观众想要什么并把脚捏舒服才是当下商业作品最重要的事”正确预测为恐惧，图像分支却预测为开心，最终融合结果仍为开心；案例 2 真实标签为悲伤，文本判断正确，但融合结果分别跟随图像分支被判为开心和惊喜。这说明当前决策层融合可能采用了固定权重，或图像模型输出的置信度整体偏高，使文本模态在发生冲突时缺乏足够的决策影响力。



案例 004



案例 005

失败案例中也有部分被文本模型带偏的情况，如案例 4 中，图像模型成功识别为开心，但是在文本上“看了好些遍，还是喜欢，张国荣在桥上给钟楚红一个熊抱，还喊着‘大胖妞儿’……印象深刻呵。他们三人这样简单而深刻的感情是非常非常可贵难得地”预测为平淡，最后结果被文本带偏，预测错误

同样也有两个模态都错误的情况，例如案例和 5 中，文本模型预计依靠“被一次次压抑、扼杀、窒息。真希望每个妈妈都能带女儿去看这部电影”预测为悲伤，图像预测为惊喜

从错误类别看，图像分支容易将悲伤、恐惧和平淡误判为开心、惊喜或平淡，表明电影海报中的妆造、光照、姿态以及艺术化构图会干扰面部表情识别。文本分支虽然在本组案例中的正确率更高，但也会受到评论与海报人物弱相关、反讽、网络化表达以及评论侧重剧情或主题分析等因素影响。因此，这些错误并非只来自单模态模型精度不足，也与图文信息并不严格对应有关。

B.成功案例上



案例 1



案例 2

在成功案例上，出现不少文本模型成功纠正结果的案例，例如案例 1 图像识别成平淡，但成功被评论纠正为悲伤，案例 2 图像预测为惊喜，成功被文本纠正为平淡，案例 1 上预计识别“不要破坏太空电梯”中破坏一词的识别出悲伤情绪，纠正结果为悲伤，案例 2 上预计识别“文戏真不够武戏耐看”这一评论认为电影较为平淡给出平淡结果，成功纠正结果，这说明文本的融入确实能对结果预测带来一定改善



案例 3



案例 4

同样也存在不少图像预测成功未被评论错误结果的案例，案例 3 上图像成功预测为悲伤，而评论预计依靠“调子特别沉静，风格很美，有大师风范。最后特别受不了菊之助的凉薄”“黯淡无光”预测为平淡，但最终结果预测为悲伤，未被评论的错误结果影响，又如案例 4 图像成功预测为平淡，但评论错误识别成害怕，最终结果仍然为平淡。

按道理来讲应该也会存在以为模型给出权重不高，导致两模态都预测成功但是结果失败或者预测都失败但结果成功，不过这种情况确实少见，在案例中也未出现这种情况

总体而言，晚期融合虽然比早期融合更加简单，但其独立预测后再合并的机制无法理解图像表情与评论语义之间的具体对应关系。当两种模态相互矛盾时，模型给出的预测权重会对结果影响较大，最终结果会偏向与最终权重总和较高的预测结果，从案例结果上看，成功案例中受到评论纠正的案例较高，而失败案例中多是坚持图像预测的失败结果，这一点说明在图像具有一定情感预测的前提下，对于图像未能成功预测的样本能够有效纠正。

目前前沿 SOTA 的多模态情感识别准确率可以达到 85 左右，我们则是达到了最高 81 的准确率，虽有一定距离但是可见融合的效果还是相当好的。

(六) 连续情感分析效果。扩展任务

图 17、图 18 为连续情感 VAD 预测示例，图 19 为连续情感训练曲线。VAD 中 V 表示情感强度，A 表示愉悦程度，D 表示主动程度。相比七类离散情感分类，连续情感预测能够表达情绪强弱和变化方向，更适合摄像头连续检测场景。最后我们的模型在这三个维度上的误差均值在 2 左右（范围为 0~10）



True VAD: (9.00, 8.00, 2.00)
Pred VAD: (6.80, 5.31, 6.33)
MAE: 3.0741



True VAD: (4.00, 7.00, 3.00)
Pred VAD: (6.87, 5.24, 7.45)
MAE: 3.0270






图 17 连续情感 VAD 示例一；图 18 连续情感 VAD 示例二；图 19 连续情感训练曲线

从图 17 和图 18 可以看出，当人脸较清晰、表情特征较明显时，模型预测的 VAD 值能够接近真实标注，说明连续模型已经学习到表情强度与三维情绪空间之间的对应关系；但不同样本的 MAE 仍有差异，说明姿态、光照、表情幅度和个体差异会影响连续预测精度。图 19 显示连续情感模型训练过程中训练损失下降较快，但验证表现仍有波动，说明模型能拟合训练样本，却仍需要通过数据平衡、离散情感先验锁定和更合适的数据集来提升泛化能力。

实际上该数据集下同样存在样本不均衡问题，对于这一问题统一放在第四部分第一点讨论

(七) 摄像头调用实时识别情感（扩展任务）





识别上采取了后面说的连续情感识别方法，同时进行七类情感识别加连续情感识别，体验上，开心，平淡，厌恶，惊喜表情较为容易识别，而悲伤，愤怒，惧怕三个表情比较难以识别，愤怒容易被识别成为惊喜，并且眼镜对于预测结果也有一定影响，悲伤和愤怒表情难以在佩戴眼镜时被识别，这个结果可能会因人而异，另外模型缺乏对于微表情的分析能力，只能对一些大幅度表情进行准确的识别。

其次是摄像头截取人脸上，虽然 `mtcnn` 对于人脸的截取精度和效果远高于 `opencv`，但是其开销较大，但无法配合做到无卡顿实时检测人脸，故实时监测上采取 `opencv` 作为人脸截取，但其容易截取错误以及识别不到人脸，并且对于人脸无遮挡要求较高

另外，我们对于识别上加上了滤波处理，采用 15 帧内的加权平均值作为结果，使得预测更加连续丝滑，体验更好，这里可以从 `camera` 的两个文件中体验出来。

四、创新点

结合训练日志、验证指标与测试集结果，本文从样本不均衡处理、离散情感类型先验锁定和实时自监督适应三个方面总结本项目创新点，并进一步分析其对模型稳定性、泛化能力和实际应用价值的影响。

（一）基于加权交叉熵损失和分层数据集划分适应样本不均衡

该方法的有效性在我们自己创建的电影封面人脸数据集与 Emotic 数据集下均得到验证

在创建的电影封面数据集上存在标签偏置问题，训练损失会被样本数量占优的大类主导，梯度更新过度偏向高频标签。加上数据集规模较小，模型容易产生明显的多数类偏置，推理阶段倾向于反复预测样本量大的标签，忽视样本稀缺的小众类别，最终造成少数类别识别效果差、整体分类预测分布偏移的问题。为处理这一问题，本项目采取了以下措施：

1. 加权交叉熵损失：针对不同类别设置损失权重，样本越少的类别权重越大；再通过归一化使权重均值为 1。这样稀有类样本产生的损失会被放大，反向传播时小类别梯度影响力提升，从而抵消大量多数类样本对损失函数的主导作用。

2. 均衡准确率作为核心评估指标：逐类别计算单类准确率后再取均值，学习率调度器和最优模型保存均以均衡准确率作为判断标准，而非只依赖普通总体准确率，避免模型通过偏向多数类获得虚高分数。

3. 训练策略控制：适当降低学习率，减少无效迭代次数，并结合验证集指标选择最优模型，从而缓解小样本类别过拟合和特征提取失效问题。

结果上，加权损失与分层划分使预测分布更加均衡，模型不再过度集中于样本量最大的类别，少数类情感的召回能力得到改善。虽然该策略无法彻底弥补数据规模不足，但能够明显降低多数类偏置，是自建电影封面数据集中较有效的稳定化方案。




图 20 加权损失后的封面人脸训练曲线

图 20 展示了采用加权损失后封面人脸训练曲线的变化。训练损失仍能下降，说明加权策略没有破坏模型收敛；同时验证曲线相较原先更关注少数类表现，能够避免总体准确率被多数类掩盖。




图 21 平衡后预测结果；图 22 平衡前预测结果

图 21 与图 22 形成对比：平衡后混淆矩阵的预测分布更分散，对角线外的极端集中现象有所缓解；平衡前模型更容易向样本量大的类别偏移。该对比说明，加权交叉熵和均衡准确率能够改善类别偏置，但不能完全替代数据扩充。

准确率表格（与第三部分中封面人脸表格一致）

训练策略	总准确率	均衡准确率
平衡前	53%	/
平衡后	66%	52%

迁移训练	66%	54%
------	-----	-----

同样，Emotic 数据集也存在连续标签分布不均衡问题。以 V 值为例，样本大多聚集在 6 到 7 左右，若不进行处理，模型容易学习到向集中区间回归的保守预测模式。

经过平衡处理后，这一问题得到明显优化。预测结果不再局限于 6 到 7 的区间，对高强度和低强度情绪样本的表达能力增强。图 23 和图 24 分别展示了连续情感预测成功与失败的例子：相较于平衡前，平衡后的模型能够预测成功一些小区间数据，并且预测失败的例子也不再是因为一味的预测大数据量区间，更多的例子可以在文件中的预测结果例子中找到。



True VAD: (8.00, 7.00, 8.00)
Pred VAD: (8.23, 6.60, 8.54)
MAE: 0.3897



True VAD: (7.00, 4.00, 9.00)
Pred VAD: (1.67, 8.37, 1.94)
MAE: 5.5848

图 23 连续情感预测成功示例；图 24 连续情感预测失败示例

（二）离散先验配合连续模型进行三维度连续情感检测

先利用七类情感分类模型得到七个情感权重占比，随后联合 Emotic 训练得到的连续三维情感状态进行预测，其中 V 表示情感强度，A 表示愉悦程度，D 表示主动程度。具体流程为：

1. 预先框定七类情感各自的 VAD 三维情感强度区间。

（情感强度，愉悦度，主动优势度）

[0.7, 1.0, 0.15, 0.4, 0.7, 1.0],	# anger 愤怒
[0.3, 0.7, 0.2, 0.45, 0.2, 0.6],	# disgust 厌恶
[0.5, 0.9, 0.1, 0.4, 0.2, 0.5],	# fear 惧怕
[0.3, 0.9, 0.8, 1.0, 0.6, 0.85],	# happy 开心
[0.0, 0.2, 0.4, 0.6, 0.0, 0.4],	# normal 平淡
[0.4, 0.85, 0.0, 0.2, 0.0, 0.25],	# sad 悲伤
[0.4, 0.8, 0.3, 0.7, 0.6, 0.95]	# surprised 惊喜

2. 随后在不同情感区间内将预测 VAD 值线性映射到对应情感区间，使连续预测结果受到离散情感先验约束。

3. 最后将七类情感的 VAD 值按照离散预测占比进行加权求和，得到最终连续情感 VAD 值。




图 25 情感分类结果与连续情感模型预测后三维度情感结果

这样在实现连续情感分析的同时，引入离散情感类型先验锁定，能够减少连续回归模型的异常偏移，提高模型在实时场景下的容错性和可解释性。

（三）自监督自动适应不同人脸

利用人脸表情在极短时间内不会突变的特点，取相近帧内预测平均值作为该帧的伪标签进行实时自监督训练，从而让模型自动适应不同人脸、光照和摄像头环境。该方法可以选取不同范围的近似帧进行对比测定：短窗口响应更快但抗噪声较弱，长窗口更稳定但可能降低情绪变化的灵敏度。因此实际使用时需要结合置信度阈值和更新频率，同时进行了情感类别需一致的限制，避免错误伪标签持续累积。




图 26 自监督网络与原网络情感跳变对比

如图所示，在自监督网络（红线）与原网络（蓝线）情感预测跳变对比中可以看出，自监督网络对于情感的预测更加顺滑，符合人脸情感连续的特点，同时也并未失去对情绪的变化判断（这一点可以在结果中的视频看出），而原网络则出现大量毛刺，预测不稳定。

另外值得一提的是我们的自监督网络并没有直接使用全局所有帧来训练，也就是说训练帧与预测帧是时间上先后隔离的，在算力可以实时监测人脸，而不是仅仅处理视频，但由于设备原因（轻薄本 CPU 跟不上网络训练要求，云端 GPU 无法链接摄像头），我们未开发其实时监测功能，并且在云 GPU 上除去初始化等流程视频的处理速度是快于视频本身的。

五、优化提升空间

（一）调整更合适的学习策略与网络结构模型等

本项目对部分注意力机制和网络结构进行了尝试，并在准确度上得到了一定程度的提高，但相比部分期刊论文中的成熟模型仍存在一到两个百分点的差距。后续可进一步优化网络结构，尝试更合适的数据增强、正则化、学习率调度和早停策略，以提高预测精度和泛化能力。

（二）电影封面数据集本身缺陷

1.数据集本身样本不均衡问题

虽采取加权损失、分层划分等措施进行了有效平衡，但数据集本身缺陷始终无法仅通过算法彻底消除。后续仍需继续扩充样本数量，尤其补充少数类情感样本，并提高标签质量与样本多样性。

2. 封面人脸和电影评论相关度不大问题

这是本项目中文本预测效果欠佳的重要原因之一。电影评论可能更多评价剧情、演员、导演或观影体验，而封面人脸通常体现宣传设计和角色状态，二者并不总是严格对应。虽然本项目已经利用人脸与人物关联筛选出部分有用评论，但关联性仍有待提高，需进一步探究影评与电影封面人脸之间的强相关关系，以提高文本模型和多模态融合模型精度。

（三）自监督网络对算力需求较大

实时自监督须在一定电脑配置环境下才能实时运行，常规轻薄本难以持续跟进参数更新，只能进行视频离线处理。后续可通过优化自监督策略、降低更新频率、引入轻量化模型或模型蒸馏方法来减小算力需求，使系统面向更广泛的笔记本用户群体。

（四）连续情感强度预测网络效果优化

Emotic 不是单纯的表情情感数据集，其标注中帶有一定环境情感色彩影响。虽然这使模型具备进一步分析环境情绪的可能，但也会给纯表情分析带来误差。后续可选择更贴近人脸表情的连续情感数据集，或在训练中区分人脸特征与环境特征，以提高连续情感强度预测效果。

参考文献

- [1]蔡林沁,刘道宏,刘岚睿,等. 融合对抗学习与多视图网络的鲁棒多模态情感分析 [J/OL]. 软件学报, 1-22[2026-07-09]. <https://doi.org/10.13328/j.cnki.jos.007628>.
- [2]曾晓锋,刘振华,陶飞达. 基于多模态语义映射的信号特征融合与表示优化 [J]. 自动化与仪器仪表, 2026, (6) 88-92+97. DOI:10.14016/j.cnki.1001-9227.2026.06.088.
- [3]谢兆龙,王兴芬. 文本缺失下融合大语言模型的多模态情感分析 [J]. 北京信息科技大学学报(自然科学版), 2026, 41 (3) 39-48+100. DOI:10.16508/j.cnki.11-5866/n.2026.03.005.
- [4]余松森,杨荣彬,方义武. 基于注意力引导对称正定二阶表示的人脸表情识别 [J/OL]. 计算机应用, 1-9[2026-07-09]. <https://link.cnki.net/urlid/51.1307.TP.20260525.1046.008>.
- [5]周强. RDAFNet: 人脸表情识别优化研究 [J/OL]. 智能计算机与应用, 1-12[2026-07-09]. <https://doi.org/10.20169/j.issn.2095-2163.26033101>.
- [6]唐玉敏,张绪德,吴小平,等. 改进轻量网络融合注意力机制的人脸表情识别研究 [J]. 科技与创新, 2026, (4) 79-81+84. DOI:10.15913/j.cnki.kjycx.2026.04.021.
- [7]李秀中. 汶川大地震 18 年后 极重灾区绵竹全力冲刺全国“百强县”[N]. 第一财经日报, 2026-01-19 (A06). DOI:10.28207/n.cnki.ndycj.2026.000224.
- [8]熊曼辰,修立知. 多尺度特征融合并行网络的情绪识别应用研究 [J/OL]. 计算机工程与应用, 1-14[2026-07-09]. <https://link.cnki.net/urlid/11.2127.tp.20260108.1532.012>.
- [9]居锦武,梁逢财,石睿. 基于 CNN 和 Transformer 融合的人脸表情识别方法研究 [J]. 新乡学院学报, 2025, 42 (12) 48-53.

成员分工说明

组长：周彬（2024141450229）

负责工作：项目整体架构与实验流程设计，提出并落地项目创新点，完成代码开发、模型训练以及全套实验方案落地，统筹团队沟通、把控项目整体进度

贡献度：30%

组员：陈俞静（2024141450289）

负责工作：爬取海报、影评原始数据，参与数据集人工标注，撰写完整实验报告，完成实验结果的解读与数据分析

贡献度：19%

组员：陈天胤（2024141450232）

负责工作：参与整体框架设计，开展人工标注任务，完成数据预清理、预处理，规范化管理项目文件结构，完成 PPT 初稿制作

贡献度：17%

组员：朱翰超（2024141470214）

负责工作：参与整体框架设计与数据人工标注，从理论层面验证创新点的合理性，最终审核、修订实验报告

贡献度：16%

组员：冯宇菡（2024141450315）

负责工作：参与整体框架设计以及人工标注工作，检索相关文献、敲定优化方案，完成 PPT 后期校对与定稿监修

贡献度：18%